

Introdução

- Abordagem probabilística (Teorema de Bayes)
- Exemplos
 - Filtros de spam
 - Mineração de emoções
 - Separação de documentos

Base original

História do crédito	Dívida	Garantias	Renda anual	Risco
Ruim	Alta	Nenhuma	< 15.000	Alto
Desconhecida	Alta	Nenhuma	>= 15.000 a <= 35.000	Alto
Desconhecida	Baixa	Nenhuma	>= 15.000 a <= 35.000	Moderado
Desconhecida	Baixa	Nenhuma	> 35.000	Alto
Desconhecida	Baixa	Nenhuma	> 35.000	Baixo
Desconhecida	Baixa	Adequada	> 35.000	Baixo
Ruim	Baixa	Nenhuma	< 15.000	Alto
Ruim	Baixa	Adequada	> 35.000	Moderado
Boa	Baixa	Nenhuma	> 35.000	Baixo
Boa	Alta	Adequada	> 35.000	Baixo
Boa	Alta	Nenhuma	< 15.000	Alto
Boa	Alta	Nenhuma	>= 15.000 a <= 35.000	Moderado
Boa	Alta	Nenhuma	> 35.0000	Baixo
Ruim	Alta	Nenhuma	>= 15.000 a <= 35.000	Alto

Naive Bayes

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa 5	Desconhecida 5	Ruim 4	Alta 7	Baixa 7	Nenhuma 11	Adequada 3	< 15000 3	>= 15000 <= 35000 4	> 35000 7
Alto 6/14	1/6	2/6	3/6	4/6	2/6	6/6	0	3/6	2/6	1/6
Moderado 3/14	1/3	1/3	1/3	1/3	2/3	2/3	1/3	0	2/3	1/3
Baixo 5/14	3/5	2/5	0	2/5	3/5	3/5	2/5	0	0	5/5

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa	Desconhecida	Ruim							
	5	5	4							
	1/6	2/6	3/6							
Alto 6/14										
Moderado 3/14	1/3	1/3	1/3							
Baixo 5/14	3/5	2/5	0							

História do crédito	Risco
Ruim	Alto
Desconhecida	Alto
Desconhecida	Moderado
Desconhecida	Alto
Desconhecida	Baixo
Desconhecida	Baixo
Ruim	Alto
Ruim	Moderado
Boa	Baixo
Boa	Baixo
Boa	Alto
Boa	Moderado
Boa	Baixo
Ruim	Alto

Risco de crédito	História do crédito			Dívida		Garantias		Renda anual		
	Boa 5	Desconhecida 5	Ruim 4	Alta 7	Baixa 7					
Alto 6/14	1/6	2/6	3/6	4/6	2/6					
	1/3	1/3	1/3	1/3	2/3					
Baixo 5/14	3/5	2/5	0	2/5	3/5					

Dívida	Risco
Alta	Alto
Alta	Alto
Baixa	Moderado
Baixa	Alto
Baixa	Baixo
Baixa	Baixo
Baixa	Alto
Baixa	Moderado
Baixa	Baixo
Alta	Baixo
Alta	Alto
Alta	Moderado
Alta	Baixo
Alta	Alto


Risco de crédito	História do crédito				Dívida		Garantias		Renda anual		
	Boa	Desconhecida	Ruim		Alta	Baixa	Nenhuma	Adequada	< 15	>= 15 <= 35	> 35
	5	5	4		7	7	11	3	3	4	7
	1/6	2/6	3/6		4/6	2/6	6/6	0	3/6	2/6	1/6
	1/3	1/3	1/3		1/3	2/3	2/3	1/3	0	2/3	1/3
Baixo 5/14	3/5	2/5	0		2/5	3/5	3/5	2/5	0	0	5/5

Renda anual	Risco
< 15.000	Alto
>= 15.000 a <= 35.000	Alto
>= 15.000 a <= 35.000	Moderado
> 35.000	Alto
> 35.000	Baixo
> 35.000	Baixo
< 15.000	Alto
> 35.000	Moderado
> 35.000	Baixo
> 35.000	Baixo
< 15.000	Alto
>= 15.000 a <= 35.000	Moderado
> 35.0000	Baixo
>= 15.000 a <= 35.000	Alto

$$P(\text{vermelho}) = 7 / 12$$

$$P(\text{azul}) = 5 / 12$$

Probabilidades apriori



$$P'(\text{vermelho}) = 3 / 7$$

$$P'(\text{azul}) = 1 / 5$$

Probabilidades posteori

$$P''(\text{vermelho}) = 7 / 12 * 3 / 7 = 21 / 84 = \mathbf{0,25}$$

$$P''(\text{azul}) = 5 / 12 * 1 / 5 = 5 / 60 = \mathbf{0,08}$$

Vantagens x desvantagens

- Vantagens
 - Rápido
 - Simplicidade de interpretação
 - Trabalha com altas dimensões
 - Boas previsões em bases pequenas
- Desvantagem
 - Combinação de características (atributos independentes) – cada par de características são independentes – nem sempre é verdade

Conclusão