

Atividade Prática Final – Projeto Integrado em Data Science

Objetivo

Desenvolver um projeto completo de **Ciência de Dados** utilizando microdados do **ENEM** (INEP), passando pelas etapas de pré-processamento, análise exploratória em formato de relatório, visualização em Power BI e aplicação de algoritmos de regressão e classificação.

Estrutura do Trabalho

O projeto será realizado **individualmente**.

1. Pré-processamento dos dados

- Usar NU_INSCRICAO para unir as tabelas de **dados socioeconômicos** (Q001–Q023, idade, sexo, cor/raça, tipo de escola, etc.) e **resultados** (notas das provas).
- Preencher com **zero** os faltantes (representando alunos que não compareceram).
- Criar coluna **FALTANTE**:
 - **1 = Faltante** → todas as notas zeradas.
 - **0 = Presente** → pelo menos uma nota não nula.
- Separar em dois dataframes:
 - **df_classificacao**: prever FALTANTE.
 - **df_regressao**: apenas alunos presentes, prever NU_NOTA_REDACAO e NU_NOTA_MT.
- Tratar variáveis categóricas:
 - **LabelEncoder** para variáveis ordinais (ex.: escolaridade dos pais).
 - **OneHotEncoder** para variáveis nominais (ex.: sexo, cor/raça).
- Normalizar variáveis numéricas com **Min-Max Scaling**.

Entregável: código com os dois dataframes finais.

2. Análise Exploratória dos Dados (EDA)

A EDA será entregue como um **relatório de perguntas e respostas**. Cada pergunta deve ser respondida com:

- **Um gráfico** (histograma, boxplot, barra, dispersão, heatmap).
- **Uma explicação curta (2–3 frases)** sobre o que o gráfico mostra.

Perguntas orientadoras (mínimo):

1. Qual a proporção de alunos **faltantes vs. presentes**?
2. Como se distribuem as notas de **Redação e Matemática** entre os presentes?
3. As notas variam por **sexo**? E por **cor/raça**?
4. Há diferença de desempenho entre alunos de **escolas públicas e privadas**?
5. Como a **renda familiar (Q006)** se relaciona com as notas médias?
6. Existe correlação entre idade/faixa etária e desempenho?
7. Quais preditores têm maior correlação com as notas (heatmap)?
8. Quais preditores têm maior correlação com as faltas (heatmap)?

Entregável: Código/relatório em word com print dos gráficos e explicações.

3. Power BI – Modelo Estrela e Dashboard

- **Modelo Estrela sugerido:**

- **dim_aluno:** idade, sexo, cor, tipo de escola.
- **dim_socioeconomico:** Q001–Q023.
- **dim_local:** município/UF da prova.
- **dim_tempo:** ano da prova.
- **fact_resultado:** notas (Redação, Matemática, demais áreas), FALTANTE.

- **Dashboard obrigatório (mínimo 3 páginas):**

1. **Visão Geral** → indicadores nacionais (média, mediana, % faltantes).
2. **Perfil Socioeconômico** → cruzamentos de renda, tipo de escola, sexo, cor/raça × desempenho/faltantes.
3. **Mapa Geográfico** → distribuição de faltantes por UF e médias de notas por região.

- **Publicação:**

- Publicar o dashboard no **Power BI Service**.
- Entregar o link compartilhável **ou** apresentação local do arquivo .pbix.

Entregável: Dashboard completo com pelo menos 3 páginas + link publicado (Opcional).

4. Modelagem de Machine Learning

- **Classificação (obrigatória):**

- Prever FALTANTE (0 = Presente, 1 = Faltante).
- Algoritmos:
 - **Rede Neural (MLP)**
 - **SVM (Support Vector Machine)**
 - **Outro à escolha** (Random Forest, KNN, etc.)
- Avaliar com: Matriz de confusão, Acurácia, F1-Score.
- Discutir desbalanceamento das classes.

- **Regressão (obrigatória):**

- Prever NU_NOTA_REDACAO e NU_NOTA_MT (somente presentes).
- Algoritmos:
 - **Rede Neural (MLP)**
 - **SVM Regressor**
 - **Outro à escolha** (Random Forest Regressor, Regressão Linear, Regressão Polinomial etc.)
- Avaliar com: RMSE, MAE, R^2 .

- **Opcional (extra):**

- Criar coluna DESEMPENHO (Boa/Média/Ruim) com base na média das 5 provas.
- Prever DESEMPENHO.

Entregável: Código com os experimentos, métricas e relatório comparativo.

5. GitHub

O gerenciamento do projeto deve acontecer **desde a primeira semana**.

Requisitos mínimos do repositório:

- Estrutura organizada:
- data/ # datasets tratados
- Códigos/ # pré-processamento, EDA, modelagem
- bi/ # arquivo Power BI (.pbix)
- README.md # documentação do projeto
- Commits semanais mostrando evolução.
- README com:
 - Objetivo do projeto.
 - Estrutura dos dados.
 - Etapas realizadas.
 - Instruções para reprodução (Opcional).

Opcionais (Desafio)

- **Banco de Dados (MySQL/PostgreSQL):** carregar dados tratados, consultar via Python e conectar ao BI.
- **Interface (Streamlit, Flask, ou qualquer outro):** app simples para entrada e saída de dados.

Cronograma – 6 semanas

Semana	Atividade	Entregáveis
1	Pré-processamento + Estruturação do GitHub	Código unindo socioeconômico + resultados, criação de FALTANTE, separação em df_classificacao e df_regressao, normalização e encoding; repositório GitHub iniciado e estruturado.
2	Análise Exploratória (EDA) – Parte 1	Relatório com perguntas iniciais respondidas (proporção de faltantes, distribuição das notas, gráficos básicos) + explicações curtas.
3	Análise Exploratória (EDA) – Parte 2	Relatório com perguntas avançadas (relações socioeconômicas, renda × notas, correlações, comparações entre grupos).
4	Power BI	Arquivo .pbix com modelo estrela implementado, dashboards (mín. 3 páginas: visão geral, perfil socioeconômico, mapa geográfico) + publicação no Power BI Service.
5	Modelagem de Machine Learning	Código com classificação (FALTANTE) e regressão (Redação e Matemática), usando pelo menos 3 algoritmos em cada tarefa; relatório de métricas comparativas.
6	Revisão e Entrega Final	Repositório GitHub completo e atualizado (data/, códigos/, bi/, README.md); refinamento dos dashboards e códigos; entrega consolidada.